Memória Virtual

João Paulo

Grupo de Sistemas Distribuídos
Departamento de Informática
Universidade do Minho

Memória virtual

- Separar o conceito de memória lógica/virtual que os processos manipulam da sua existência em memória física
- Apenas parte do programa necessita de estar em memória em cada instante
- Espaço de endereçamento virtual manipulado pode ser muito maior do que a memória física
- Memória secundária (disco) usada para guardar partes da memória virtual
- Pode ser implementada via paginação ou segmentação
- Implementada eficientemente via paginação on demand

Espaço de endereçamento lógico/virtual de processo

- Não pode ser prevista à partida memória necessária
- Grande espaço de endereçamento com stack “longe” do heap
- E se espaço de endereçamento maior do que memória física?
- Processo não usa todo espaço de endereçamento; e.g. arrays definidos por excesso; rotinas não usadas

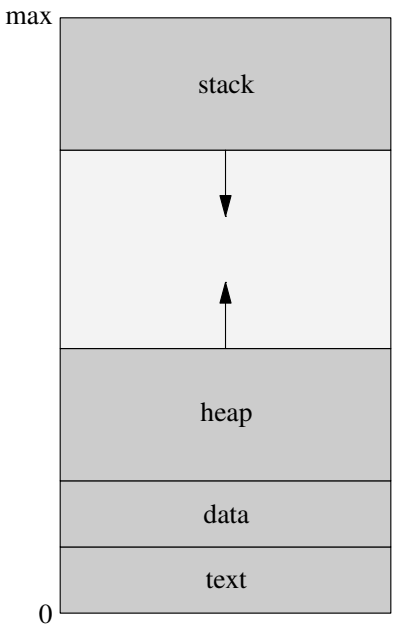

Benefícios de processo parcialmente em memória

- Tamanho do progama não seria constrangido pela memória física:
  - programadores escrevem para espaço virtual grande
  - programas funcionam em máquinas com diferente memória
- Cada programa necessita de menos memória:
  - mais processos ao mesmo tempo
  - maior utilização de CPU
- Menos I/O a carregar ou fazer swap; programas correm mais rápido

Partilha de memória e ficheiros

Sistemas de memória virtual permitem tipicamente:

- Partilha de bibliotecas entre processos via objectos partilhados mapeados na mesma memória física
- Partilha de memória para comunicação entre processos
- Partilha de páginas na criação de processos com fork

Demand paging

- Usado em sistemas de memória virtual
- Em vez de fazer swap-in de todas as páginas do processo . . .
- Trazer página para memória apenas quando necessária:
  - menos I/O
  - menos memória necessária
  - resposta mais rápida
  - menos memória por processo; mais processos em memória
- Pager: lazy swapper – só traz página para memória se necessária
- Página endereçada; possibilidades
  - página inválida – abortar programa
  - página não presente – trazer para memória

Bit de válido/inválido na tabela de páginas

- Cada entrada na tabela de páginas tem bit válido/inválido
- Bit é aproveitado para implementar memória virtual:
- Válido: se endereço válido e página mapeada em memória física
- Inválido se:
  - página inválida
  - página em disco; não mapeada em memória física
- E se endereçada página com bit inválido?

Page fault

- Quando endereçada página com bit inválido – trap de endereçamento: page-fault
- Sistema operativo consulta outra tabela e decide:
  - endereço inválido: aborta programa
  - página não presente em memória: trazer página
- Passos para trazer página:
  - encontrar e alocar frame livre
  - escalonar leitura da página em disco para a frame
  - executar outro processo
  - mais tarde, aquando interrupção leitura terminada:
    - modificar tabela de páginas marcando página válida;
    - recomeçar execução de instrução interrompida
- Estes passos são transparentes ao processo, que recomeça como se a página sempre estivesse em memória

Suporte a demand paging

- O suporte de hardware para demand paging é:
  - tabela de páginas; com bit válido/inválido
  - memória secundária – swap space: área de disco dedicada
  - recomeço de execução de instrução aquando page-fault
- O recomeço de execução de instruções pode ser complicado:
  - instruções de transferência de blocos
    e se houver sobreposição fonte-destino?

Performance de demand paging

- Quando há page-fault, é necessário:
  - servir interrupção
  - ler página
  - recomeçar processo
- Trazer página demora; e.g. 8ms
- Mesmo podendo executar outro processo entretanto:
  - se este novo processo causa page-fault . . .
  - pode conduzir a todos os processos à espera das páginas
- Performance dependente do page-fault rate p

Performance de demand paging

- Com acesso à memória m e a trazer página de disco d
- Tempo de acesso efectivo:

$$TAE = (1 - p) \times m + p \times d$$

- Se $m = 200ns$, $d = 8ms$ e $p = 1/1000$:
  TAE = 8200ns = 41 m
- Essencial que p seja muito baixo
- Com valores m e d acima, para não haver degradação de desempenho necessário $p < 1/40000$

Copy-on-write

- Permite processos pai e filho partilhar páginas inicialmente
- Página só é copiada quando um deles tenta modificar página
- Página é marcada na tabela de páginas para permitir detecção; e.g. bits de permissão
- Permite criação eficiente de processos via fork

E se não houver frames livres?

- Ao trazer páginas de disco, eventualmente memória cheia
- Quando não há frames livres, necessário libertar frame
- Necessário escolher página para libertar
- Como escolher?
  - páginas que não estejam a ser muito usadas
  - necessário algoritmo de substituição de páginas (page replacement)
- Páginas alternam entre memória e disco; podem ser trazidas várias vezes de disco

Substituição de páginas

- Rotina de tratamento de page-faults modificada para incluir libertar páginas
- Páginas em memória que não tenham sido modificadas não necessitam de ser escritas em disco
- Como saber se foi modificada?
  - via modify (dirty) bit - colocado a 1 quando página modificada
  - e se não houver suporte de hardware?
- Páginas modificadas são escritas em disco
- Páginas libertadas são marcadas como inválidas

Substituição de páginas - passos básicos

1. Encontrar página em falta no disco
2. Encontrar uma frame livre:
   - se houver livre – usar
   - caso contrário:
     1. correr algoritmo para seleccionar vítima
     2. marcar página inválida
     3. transferir para disco se modificada
3. Trazer página para a frame libertada
4. Actualizar tabelas de páginas e frames
5. Recomeçar processo

Algortimos de substituição de páginas

- Objectivo: minimizar a frequência de page-fault
- Como avaliar algoritmos?
  - correr algoritmo sobre sequência de referencias à memória
  - e.g. 1,2,3,4,1,2,5,1,2,3,4,5
  - contar o número de page-faults ocorrido
- Vários algoritmos possíveis:
  - FIFO
  - Óptimo
  - LRU
  - Bit de referência
  - Second-chance
  - Via contadores

FIFO

- Expulsa a página há mais tempo em memória
- Pode ser implementado com lista ligada de páginas
- Lista apenas actualizada em page-faults
- Simples mas mau algoritmo
- Exemplo: com referências 1,2,3,4,1,2,5,1,2,3,4,5
- Com 3 frames, 9 page-faults:

1	1	1	4	4	4	5	5	5
	2	2	2	1	1	1	3	3
		3	3	3	2	2	2	4

- Com 4 frames, 10 page-faults:

1	1	1	1	5	5	5	5	4	4
	2	2	2	2	1	1	1	1	5
		3	3	3	3	2	2	2	2
			4	4	4	4	3	3	3

Anomalia de Belady

- Esperado que com mais frames menos page-faults ocorram
- Nem sempre é verdade; e.g. no FIFO
- Anomalia de Belady: mais frames $\rightarrow$ mais page-faults

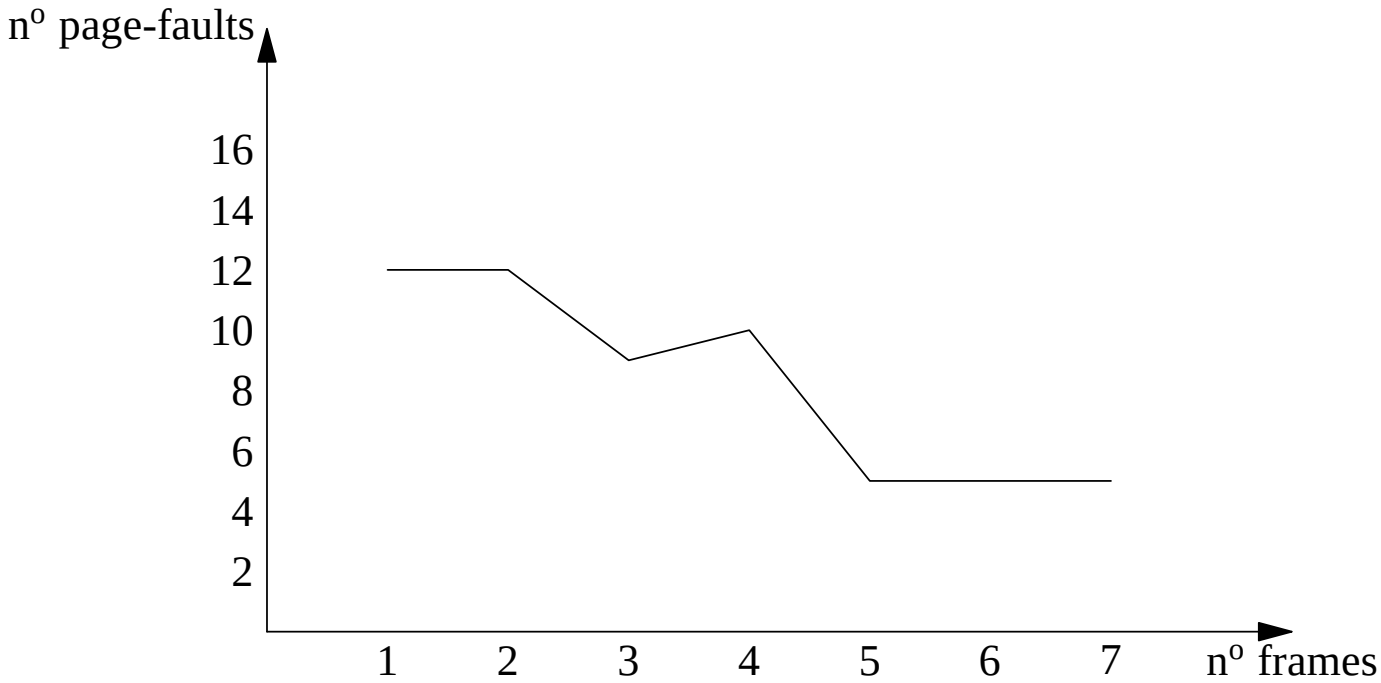

Algoritmo óptimo

- Expulsa a página que não será usada durante mais tempo
- Exemplo: com referências 1,2,3,4,1,2,5,1,2,3,4,5
- Com 4 frames, 6 page-faults:

1	1	1	1	1	4
	2	2	2	2	2
		3	3	3	3
			4	5	5

- Impossível de implementar: necessita conhecimento do futuro
- Serve como referência do melhor que se pode fazer para avaliar outros algoritmos

LRU – least recently used

- Expulsa a página que foi usada menos recentemente
- Exemplo: com referências 1,2,3,4,1,2,5,1,2,3,4,5
- Com 4 frames, 8 page-faults:

1	1	1	1	1	1	1	5
	2	2	2	2	2	2	2
		3	3	5	5	4	4
			4	4	3	3	3

- Melhor do que FIFO
- Mais complexo de implementar: necessita registar acessos

LRU – least recently used

- Implementação com contadores:
  - cada página tem contador
  - quando referênciada, copiar relógio para contador
  - expulsar a página com contador mais antigo
- Implementação com lista duplamente ligada:
  - página referenciada – mover para um extremo
  - página a expulsar – do outro extremo
  - não necessita pesquisa
  - complexo: actualização de apontadores em memória por cada acesso

Aproximações a LRU

- LRU é interessante em teoria mas complexo
- Aproximações ao LRU são usadas
- Bit de referência:
  - inicialmente: bit=0
  - quando acedida página: bit=1
  - expulsar página com bit=0
  - aproximação grosseira: pode haver muitas ou nenhuma com bit=0
- Histórico do bit de referência:
  - mantido byte com histórico do bit de referência
  - periodicamente feito right-shift para bit mais significativo
  - expulsa página com menor valor

Aproximações a LRU

- Second-chance ou clock:
  - bit de referência + FIFO
  - se bit=0, expulsar
  - se bit=1, marcar bit=0 e avançar para próxima
  - implementado com lista circular
- Second-chance melhorado:
  - second chance + bit modificado
  - classificar páginas segundo bits de referência e modificado:
    - (0,0)
    - (0,1)
    - (1,0)
    - (1,1)
  - Expulsar a próxima da classe mais baixa

Substituição baseada em contadores

- Manter contador de referências à página
- Least frequently used (LFU):
  - substituir a página com contador menor
  - e se página com contador elevado foi acedida há muito tempo?
  - fazer right-shift do contador para provocar esquecimento exponencial
- Most frequently used (MFU):
  - substituir página com contador maior
  - racional: páginas trazidas recentemente, que ainda devem ser usadas, têm contador baixo
  - pouco interessante
- Algoritmos de implementação difícil e fracas aproximações ao óptimo; pouco usados

Buffer de páginas libertadas

- Deixar acabar frames livres prejudicial: processo que necessita de frame tem que esperar pela substituição
- Solução: quando atingido limiar, começar a rejeitar páginas
- Páginas rejeitadas vão para lista de livres
- Melhoria:
  - manter associação página–frame na lista de livres
  - em page-fault ver primeiro se está na lista de livres
  - pode ser adicionada a diferentes algoritmos de substituição
  - e.g. usada com FIFO em VAX/VMS
  - e.g. usada com second-chance em alguns UNIX
- Cuidado com transições: e.g. página rejeitada mas ainda não escrita em disco

Alocação de Frames

- Processos necessitam de várias frames para correrem
- Arquitectura dita número mínimo: para todas as instruções poderem recomeçar
- Muito poucas frames provocam rácio de page-faults elevado
- Vários processos competem por memória
- Como alocar frames?
  - alocação fixa versus prioridade
  - alocação local versus global

Alocação fixa

- Distribuir um número de frames fixas a cada processo
- Equalitária:
  - o mesmo número de frames a cada processo
  - e.g. 1000 frames, 10 processos: 100 frames a cada processo
  - problema: necessidades de memória variam muito
- Proporcinal:
  - atribuir número de frames proporcional à memória virtual necessária ao processo
  - sendo v_i memória virtual do processo i
  - e $V = \sum_i v_i$ memória virtual de todos os processos
  - e f número de frames total
  - alocação ao processo i: $f_i = f \times v_i / V$

Alocação por prioridade

- Processos de mais alta prioridade devem correr mais rápido
- Alocação pode ter em conta prioridade do processo
- Alocação proporcional à prioridade
- Esquema combinado de tamanho e prioridade dos processos

Alocação local versus global

- Alocação local:
  - a cada processo é atribuído número de frames
  - substituição de páginas local ao processo
  - comportamento não depende de outros processos
- Alocação global:
  - não é definido à partida frames por processo
  - algoritmo de substituição de páginas global: vítima escolhida pode ser do mesmo ou de outro processo
  - comportamento depende do comportamento de outros processos
  - optimiza melhor uso global da memória; melhora throughput; método mais usado

Thrashing

- Se um processo tiver muito poucas frames atribuídas:
  - quando há page fault, página é substituída . . .
  - página substituída necessária logo em seguida . . .
  - nova page-fault; page-fault rate elevadíssimo
  - processo passa mais tempo em paging do que a executar
- Diz-se que o processo está em thrashing
- Causas de thrashing:
  - demasiados requisitos de memória virtual devido a elevado grau de multiprogramação
  - pode ser causado por escalonador
  - alocação global com prioridades: trashing em processos de baixa prioridade

Thrashing e grau de multiprogramação

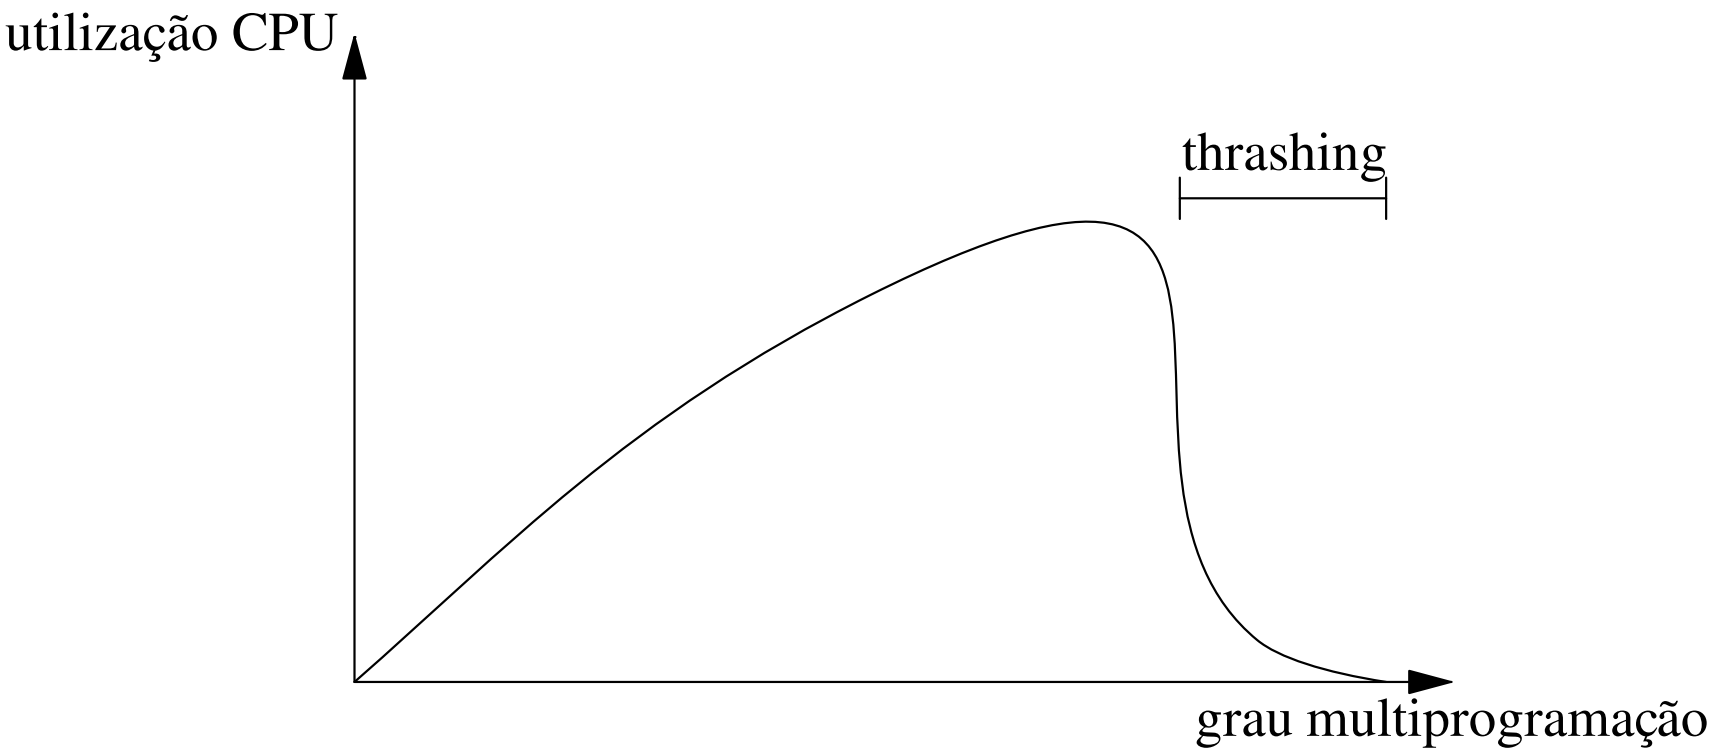

Cenário conduzente a thrashing

- Uma combinação de factores pode levar inesperadamente a thrashing:
  - substituição global de páginas
  - escalonador que olha apenas à utilização de CPU
- Sequência de eventos:
  - processo entra em nova fase e necessita páginas novas
  - começam page-faults
  - frames são obtidas retirando páginas a outros processos
  - estes processos necessitam páginas, causando mais page-faults
  - todos estes processos ficam na fila de espera de I/O
  - a ready queue esvazia-se; diminui a utilização de CPU
  - o escalonador decide aumentar grau de multiprogramação
  - novo processo retira frames aos existentes; mais page-faults
  - aumenta fila de I/O devido a paging
  - diminui ainda mais utilização de CPU
  - ciclo vicioso . . .

Prevenção de thrashing

- Quando o cenário anterior acontece a solução é diminuir o grau de multiprogramação
- O escalonador não pode olhar cegamente apenas para a utilização de CPU
- Alocação local de frames solução apenas parcial:
  - confina thrashing a um processo
  - mas mesmo num processo, thrashing prejudica o sistema todo
- Solução: dar a cada processo que corra um número apropriado de frames, ainda que limitando o grau de multiprogramação
- Como saber quantas frames são necessárias?

Localidade espacial e temporal

- Memória virtual viável porque processos não acedem à memória aleatoriamente
- Localidade espacial: se um endereço é usado, endereços próximos serão usados
- Localidade temporal: se um endereço é usado, provavelmente continuará a ser usado nos próximos instantes
  (interessante para política LRU!)
- Motivação:
  - processo executa função: usa código e stack das variáveis locais
  - ciclos levam a acesso repetido aos mesmo endereços
  - travessia de arrays leva a acessos a endereços próximos
- Resultado: um processo, em cada instante apenas acede a um conjunto (pequeno) de páginas, uma localidade
- Processos vão passando por diferentes localidades, tipicamente sobrepostas

Localidade num padrão de referências

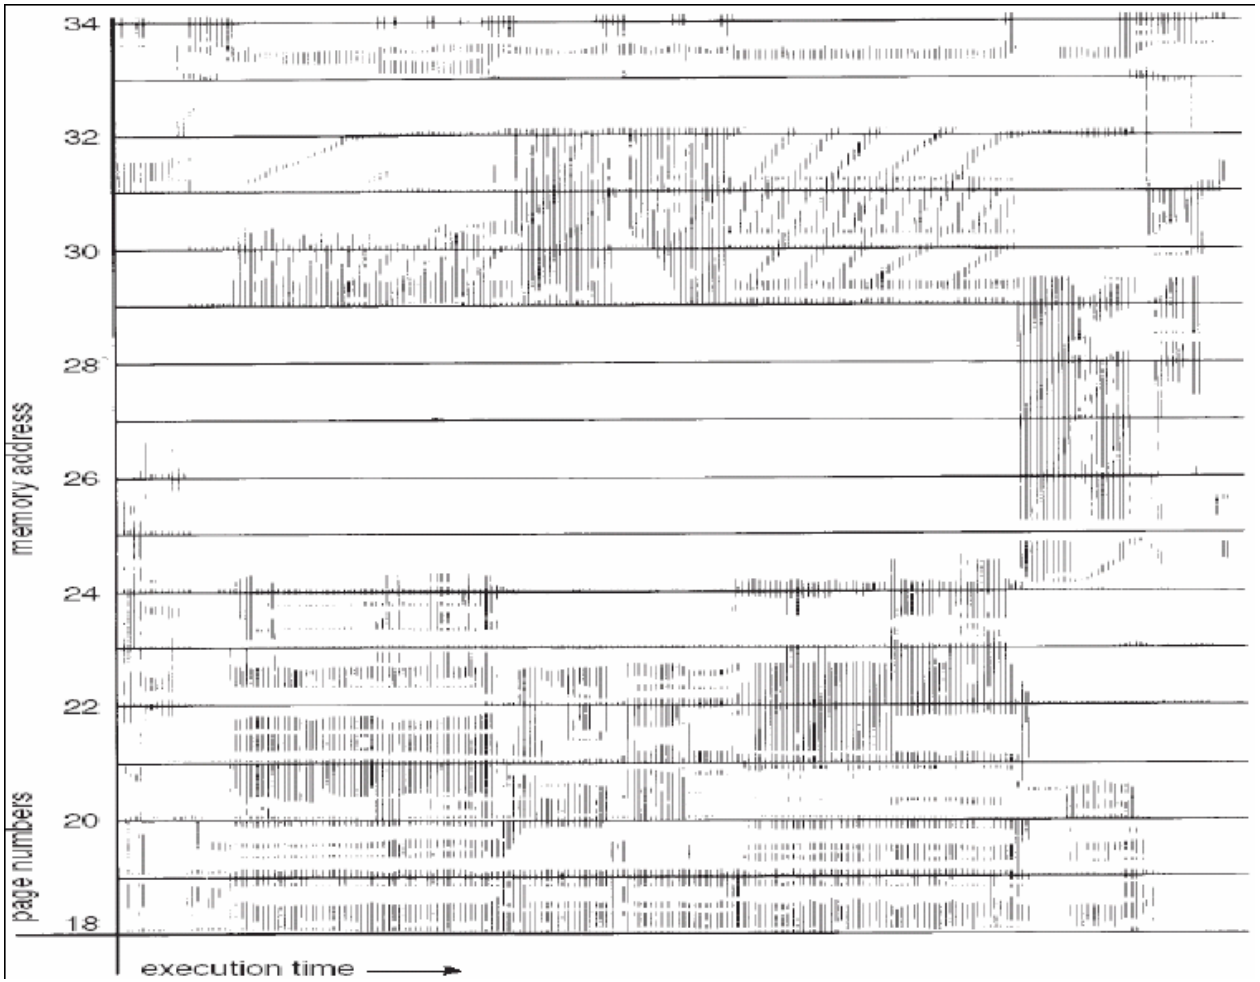

Modelo do working-set

- Working-set, para uma janela temporal Δ, é o conjunto das páginas que foram acedidos nos mais recentes Δ acessos
- Exemplo, para $\Delta = 10$:

  2 6 1 5 7 7 7 7 5 1 6 2 3 4 1 2 3 4 4 4 3 4 3 4 4 4 1 3

  t_1 t_2

  $WS_\Delta(t_1) = \{1, 2, 5, 6, 7\}$ $WS_\Delta(t_2) = \{3, 4\}$
- Working-set é uma aproximação da localidade
- Δ não pode ser demasiado pequeno nem demasiado grande
- Working-set pode ser aproximado:
  - usando um temporizador e bit de referência
  - bit referência copiado para memória e apagado
  - shift-register em memória guarda p períodos mais recentes
  - página no working-set se estiver a 1 no bit de referência ou shift-register

Evitar thrashing via working-set

Thrashing é evitado:

- dando a cada processo frames para caber o seu working set
- o working-set de cada processo varia com o tempo
- aumentar o grau de multiprogramação enquanto soma dos working-sets não exceder memória
- se soma dos working sets aumentar e exceder memória:
  - escolher um processo para suspender (swap-out)
  - alocar frames desse processo pelos restantes
  - quando necessidades diminuirem fazer swap-in do processo

Evitar thrashing via frequência de page-faults

- Thrashing significa elevada frequência de page-faults
- Medir frequência de page-faults permite controlar thrashing mais directamente
- Com mais frames: frequência de page-faults diminui
- Abordagem:
  - estabelecer limite inferior e superior de frequência
  - se limite superior ultrapassado: dar frame ao processo
  - se limite inferior ultrapassado: retirar frame ao processo
  - se não houver mais frames: suspender um processo
  - quando houver frames: trazer processo de volta

Estrutura dos programas e memória virtual

- Conhecimento do funcionamento da memória virtual pode ajudar programadores a melhorar desempenho de programas
- Exemplo:
  - dado páginas de 4KB, inteiros de 4B e `int a[1024,1024];`
  - cada linha do array ocupa uma página
- Programa 1:

```
for (j = 0; j < 1024; j++)
  for (i = 0; i < 1024; i++)
    a[i,j] = 0;
```

- Programa 2:

```
for (i = 0; i < 1024; i++)
  for (j = 0; j < 1024; j++)
    a[i,j] = 0;
```

- Com poucas frames por processo:
  - programa 1 pode causar $1024 \times 1024 = 1048576$ page-faults
  - programa 2 pode causar 1024 page-faults

Pre-paging

- Começar um processo sem páginas mapeadas leva a grande número de page-faults
- Solução: fazer pre-paging de páginas que o processo necessite
- Outra situação:
  - conhecendo o working-set de um processo
  - quando necessário suspender processo, memorizar working-set
  - quando é reactivado, fazer pre-paging do working-set
- Vantagens do pre-paging:
  - menos serviço de interrupções de page-fault
  - possível leitura em bloco do disco; mais eficiente

Influência do tamanho de página

- Páginas pequenas:
  - menor fragmentação interna
  - maior resolução: menos memória para armazenar localidade
- Páginas grandes:
  - menor tabela de páginas
  - transferência de disco mais rápida (por unidade de memória)
  - menos page-faults por gama de memória necessária
- Tendência é para maiores tamanhos e escolha por software

Ficheiros mapeados em memória

- Ficheiros mapeados em memória permitem acesso a ficheiros ser feito como acesso a memória
- Mecanismo de memória virtual é usado para mapear espaço de endereçamento do ficheiro em endereços virtuais
- Ficheiro pode ser trazido e acedido via demand paging
- Pode existir chamada ao sistema explícita (e.g. `mmap`) para mapear ficheiro em memória
- Certos sistemas operativos (e.g. Solaris) mapeiam ficheiros em memória mesmo quando acedidos via `open`, `read`, `write`
- Permite partilha: vários processos podem mapear o mesmo ficheiro num espaço partilhado

Alocação de memória no kernel

- Memória do kernel é tratada de modo diferente
- Sistemas operativos podem não submeter memória do kernel à paginação
- Ainda, é útil que dispositivos possam aceder directamente a memória física (e.g. DMA) sem passar por paginação
- Motiva gamas contíguas de memória física
- Kernel usa mecanismos próprios de alocação de memória:
  - buddy
  - slab

Sistema buddy

- Aloca memória de segmento contíguo de tamanho fixo
- Memória alocada em blocos com tamanho potência de 2:
  - pedido é arredondado para próxima potência de 2
  - espaço total, blocos alocados e livres são todos potência de 2
  - bloco livre grande é sucessivamente dividido em 2 buddies com metade do tamanho, até ao tamanho arredondado
- Fusão de blocos é simples:
  - se buddy do bloco está livre, fundir com buddy
  - repetir com o bloco resultante
- Desvantagem: grande fragmentação interna

Alocação slab

- Terminologia:
  - slab: uma ou mais páginas fisicamente contíguas
  - cache: um ou mais slabs
- Cache própria para cada tipo de estrutura de dados do kernel
- Cada cache contém objectos: instâncias da estrutura de dados
- Na criação: cache preenchida com objectos marcados livres
- Cada slab pode estar como:
  - cheio: todos os objectos estão usados
  - livre: todos os objectos estão livres
  - parcial: alguns objectos usados

Alocação slab

- Quando pedido de alocação de objecto:
  - devolvido objecto em slab parcial, senão
  - devolvido objecto em slab vazio, senão
  - novo slab alocado à cache
- Quando libertação de objecto: objecto marcado como livre
- Benefícios:
  - devolvida memória exacta para cada objecto
  - quase ausência de fragmentação
  - alocação e desalocação muito rápida
- Linux usava alocador buddy; usa slab desde o kernel 2.2