Dispositivos de Armazenamento

João Paulo

Grupo de Sistemas Distribuídos
Departamento de Informática
Universidade do Minho

Tipos de disco

- Fita Magnética
- Disco Rígido
- SSD - Solid State Drive
- Memória Persistente

Fita magnética

- Usada inicialmente para armazenamento secundário
- Guarda grande quantidade de dados
- Acesso é lento: necessário bobinar até os dados estarem por baixo da cabeça
- Transferência de dados rápida, depois de bobinada
- Acesso aleatório muito lento
- Actualmente usada para backup

Discos rígidos

- Discos rígidos
  - rodam entre 5400 and 15000 vezes por minuto (RPMs)
  - são constituidos por vários platters, cada um com
  - várias pistas, cada uma com sectores
  - o braço contém cabeças, que se deslocam juntas
  - o conjunto de pistas numa posição do braço é um cilindro
- São relevantes num disco:
  - transfer rate, mede a velocidade de transferência entre o disco e o computador
  - random-access time é o tempo que demora a posicionar a cabeça para ler um sector; é constituído por
  - seek time, para mover o braço e
  - rotational latency para o sector ficar por baixo da cabeça

Discos rígidos

- Disco são ligados ao computador por um I/O bus
  - vários tipos: EIDE, ATA, SATA, USB, Fibre Channel, SCSI
  - host controller no computador usa o bus para falar com o disk controller no dispositivo, que contém uma cache
- Existem discos amovíveis; e.g. floppy disks, em desuso
- Discos podem sofrer acidentes; e.g. head crash em que a cabeça entra em contacto com a superfície

SSDs

- Discos elétricos em vez de mecânicos (sem componentes móveis)
- Accessos aleatórios eficientes - não têm seek time (movimento braço) e rotational latency (posicionamento da cabeça)
- Organizados em páginas (sectores) agrupadas em blocos
  - blocos têm de ser apagados primeiro para serem reescritos
  - cada bloco só pode ser apagado um certo número de vezes (p.ex, 100 000 vezes) até às células não conseguirem armazenar dados
  - motiva algoritmos de wear leveling - garantem que os blocos são apagados uniformemente para aumentar tempo de vida

SSDs

- Disco são ligados ao computador por I/O bus
- Dois tipos principais: SATA e PCIe (mais rápido).
  PCIe é usado por SSDs NVMe (Non-Volatile Memory Express)
- host controller no computador usa o bus para falar com o NAND controller no dispositivo, que contém
  - uma cache
  - uma Flash Translation Layer (FTL) que mapeia endereços lógicos para as páginas do SSD, e mantém informação / gere blocos usados e livres (Garbage Collection)

Estrutura lógica dos discos

- Discos acedidos como array unidimensional de blocos lógicos
- Bloco é a unidade básica de transferência; e.g. 512 bytes, 4KBs
- Array unidimensional é mapeado em sectores sequencialmente. Por exemplo, num disco rígido:
  - o sector 0 é o primeiro da primeira pista do cilindro exterior
  - o mapeamento prossegue ao longo da pista
  - depois nas outras pistas do cilindro em direcção ao centro

Ligação dos discos

- Host-attached storage é acedida via portos de I/O que falam com um I/O bus; e.g. SATA, PCIe
- Existem outras alternativas para ligar a armazenamento externo (USB, SCSI, FC)
- SCSI:
  - SCSI é um bus que serve até 16 dispositivos num cabo
  - o SCSI initiator faz um pedido a um SCSI target
  - cada target pode ter até 8 unidades lógicas; e.g. componentes de um array RAID
- FC (Fibre Channel):
  - arquitectura série de alta velocidade
- Vários tipos de dispositivos podem ser usados: SSDs, discos rígidos, arrays RAID, CD, DVD, fita

Network-attached storage

- Network-attached storage (NAS) é um dispositivo acedido via rede em vez de um bus
- Permite conjunto de máquinas numa LAN partilhar disco
- São usados protocolos como NFS ou CIFS implementados via RPC
- Dispositivo implementa interface RPC
- Tipicamente menor performance do que armazenamento local
- Usam rede IP normal; e.g LAN
- iSCSI disponibiliza protocolo SCSI sobre IP

Storage Area Network

- Permite vários computadores ligarem-se a vários dispositivos
- Está a tornar-se comum em ambientes de grande dimensão
- Usa rede específica, separada da rede de dados normal
- Usa protocolos específicos de armazenamento
- Usa normalmente Fibre Channel

Escalonamento de disco

- Com multiprogramação é normal haver fila de pedidos de transferência de disco
- Gestão dos pedidos de transferência tenta minimizar tempo de acesso e aumentar largura de banda
- Caso de estudo: Discos Rígidos
  - tempo de acesso composto por:
    - seek time
    - rotational latency
  - tempo de acesso dominado por movimento da cabeça
  - diferentes algoritmos de escalonamento de pedidos de transferência, com diferentes resultados

FCFS – first-come first-served

- Serve pedidos por ordem
- Justo mas pouco eficiente
- Suponhamos cilindros entre 0 e 199; cabeça no cilindro 53 e
- fila de pedidos a cilindros: 98, 183, 37, 122, 14, 124, 65, 67
- Movimento total da cabeça: 640 cilindros

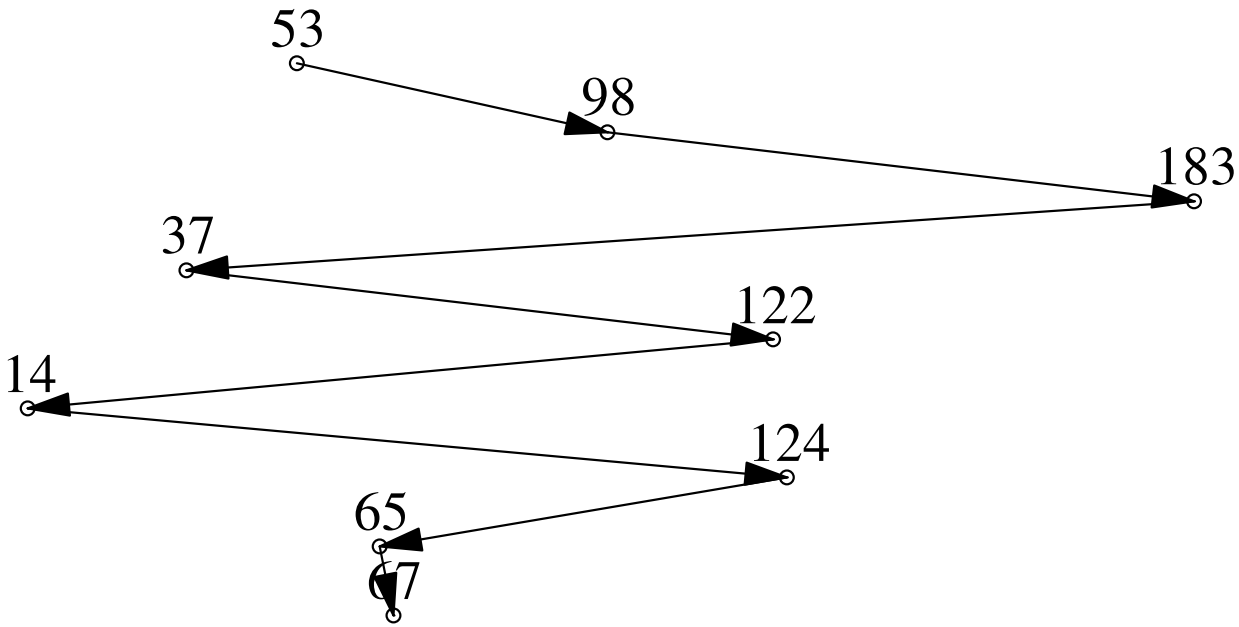

SSTF – Shortest-seek-time-first

- Escolhe pedido com o menor seek-time
- É escolhido o pedido mais perto da posição actual da cabeça
- Performance consideravelmente melhor; mas não óptimo
- Análogo a shortest-job-first; pode causar starvation
- Suponhamos mesma fila: 98, 183, 37, 122, 14, 124, 65, 67
- Movimento total da cabeça: 236 cilindros

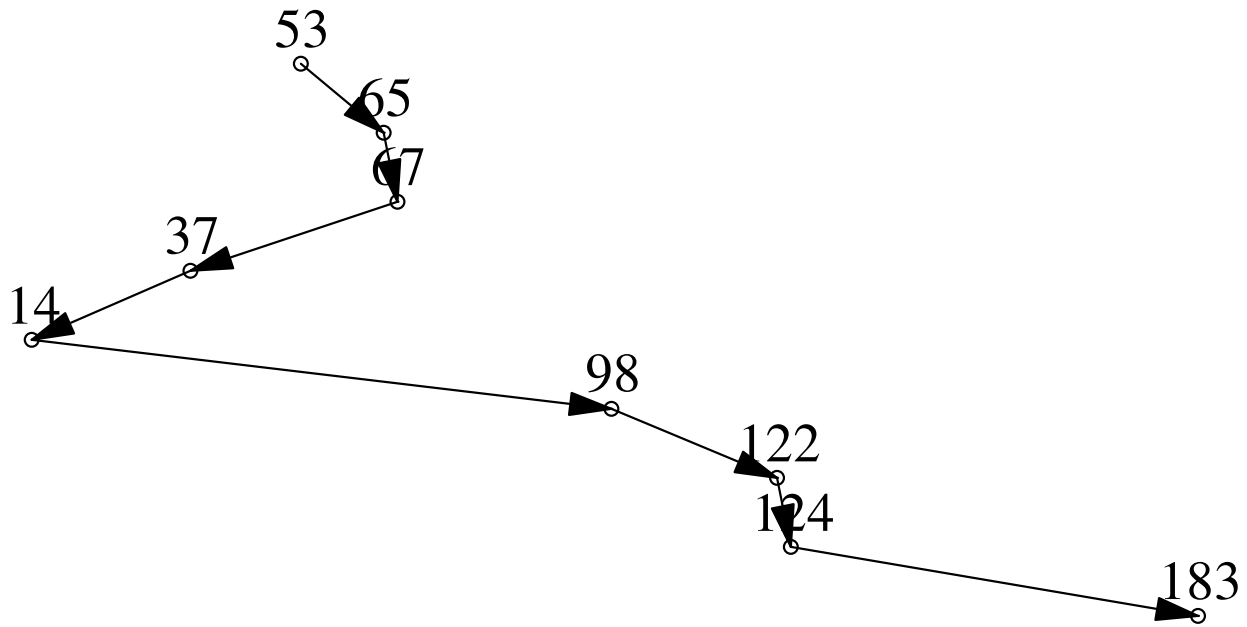

SCAN – elevator algorithm

- Cabeça desloca-se até ao fim, servindo pedidos pelo caminho
- Ao chegar ao fim, muda de direcção
- Análogo ao que faz um elevador
- Suponhamos mesma fila: 98, 183, 37, 122, 14, 124, 65, 67
- Movimento total da cabeça: 236 cilindros

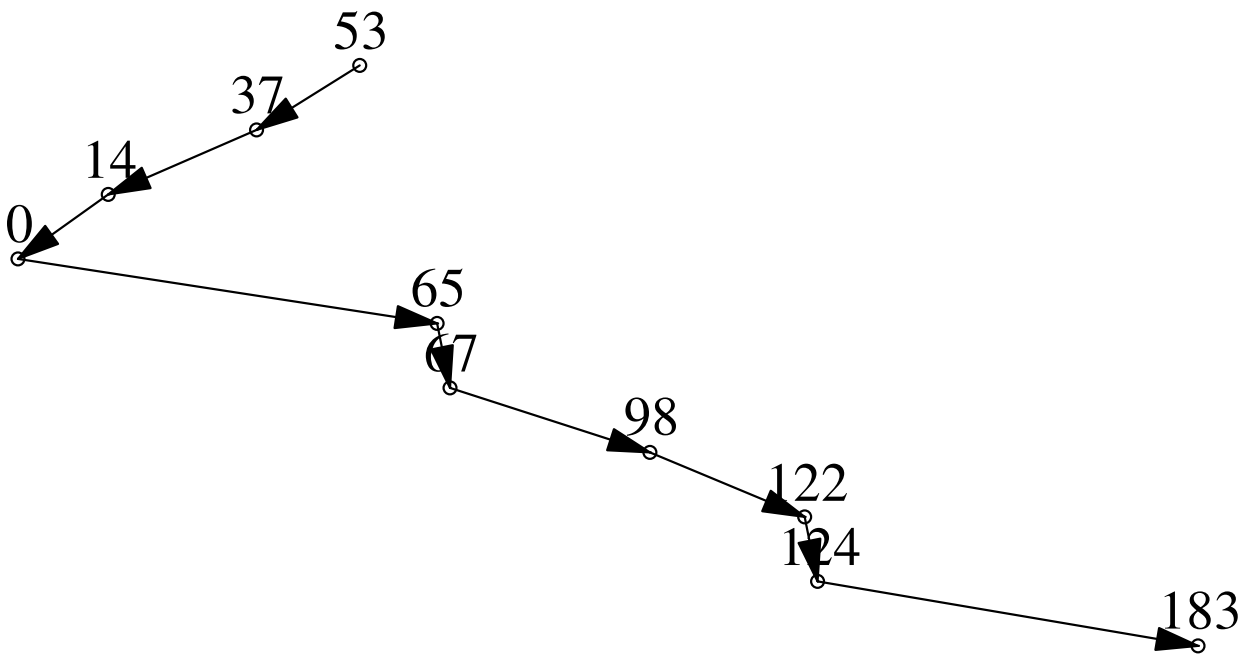

C-SCAN – Circular SCAN

- Variante de SCAN com tempo de espera mais uniforme
- Ao chegar a uma ponta, volta imediatamente ao início sem servir pedidos no caminho de volta
- Equivalente a considerar uma lista circular de cilindros
- Suponhamos mesma fila: 98, 183, 37, 122, 14, 124, 65, 67
- Movimento total da cabeça: 382 cilindros

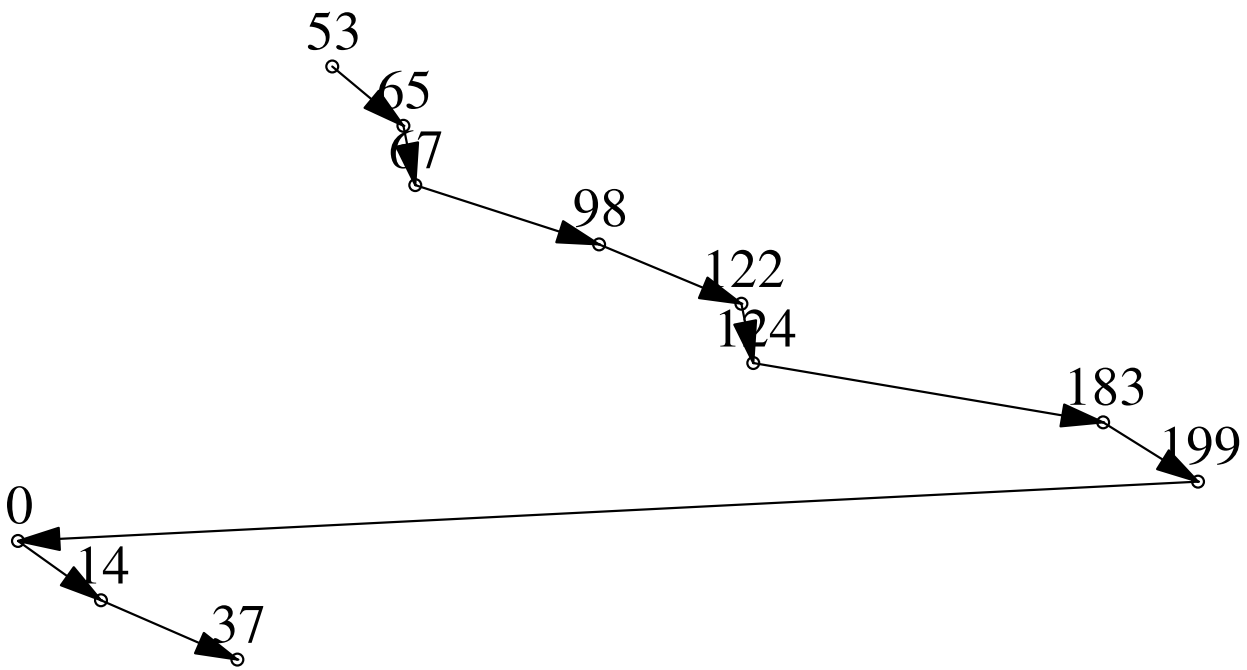

LOOK e C-LOOK

- Variantes de SCAN e C-SCAN
- Em vez de ir até ao fim, a cabeça só continua se ainda houver pedidos nessa direcção
- LOOK; mesma fila: 98, 183, 37, 122, 14, 124, 65, 67
- Movimento total da cabeça: 208 cilindros

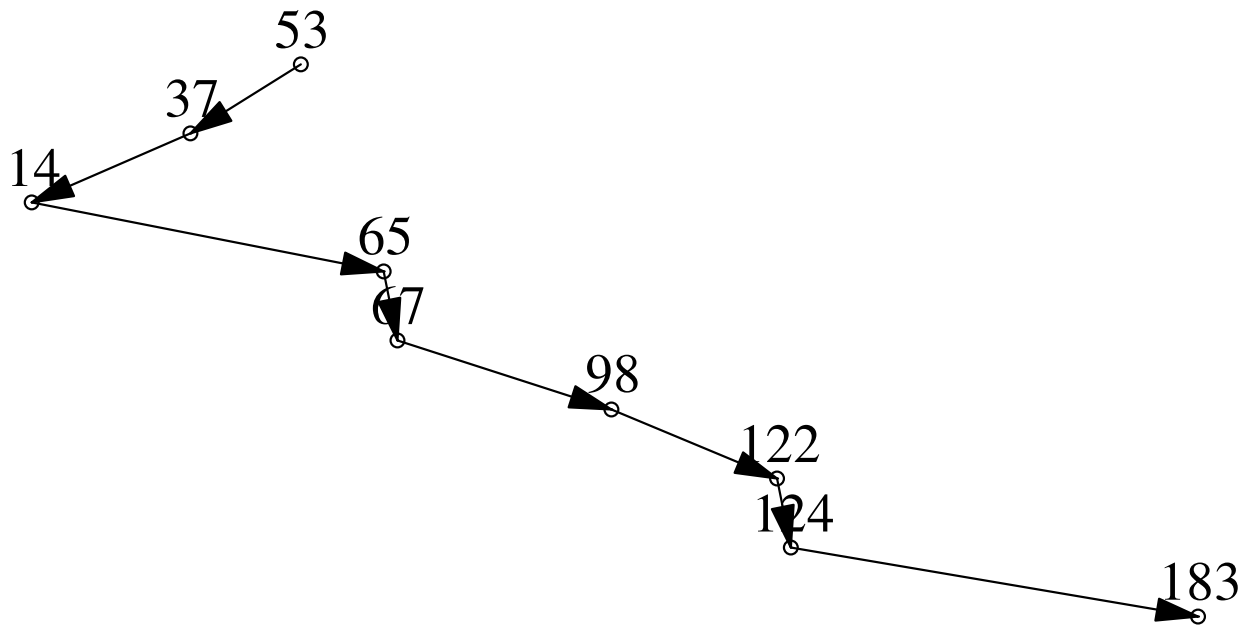

C-LOOK

- C-LOOK, mesma fila: 98, 183, 37, 122, 14, 124, 65, 67
- Movimento total da cabeça: 322 cilindros

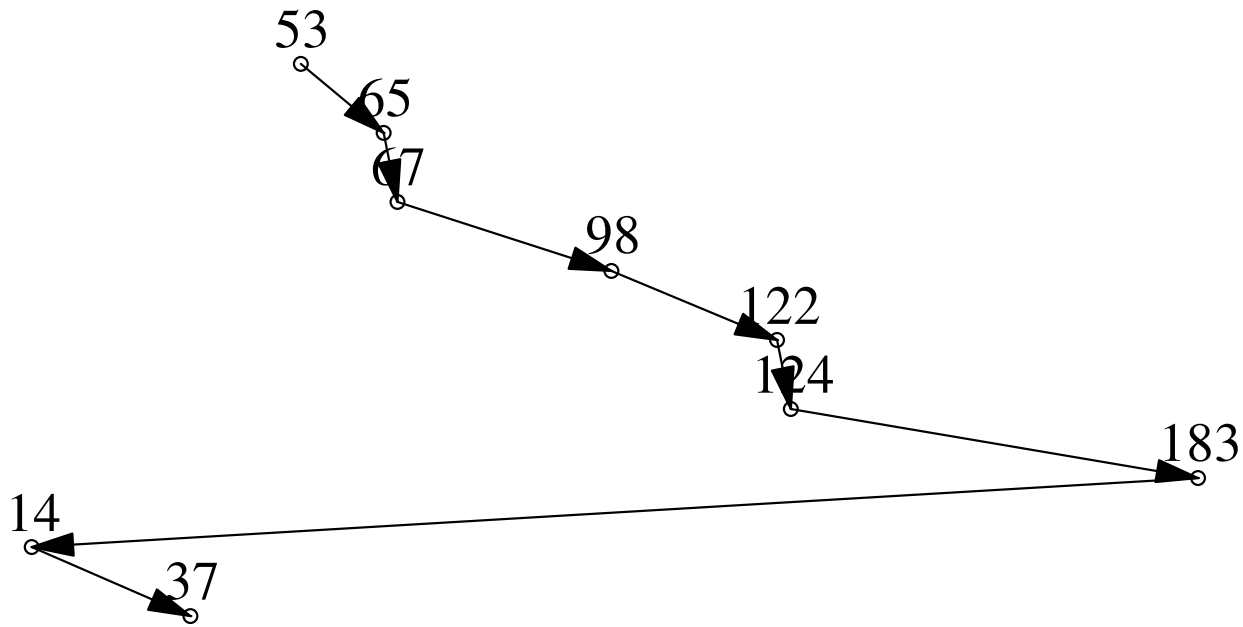

Escolha de um algoritmo

- SSTF escolha comum
- SCAN e C-SCAN melhores para grande carga; evitam starvation
- SSTF ou LOOK são escolhas razoáveis por omissão
- Performance depende do número e tipo de pedidos
- Pedidos influenciados pela alocação de ficheiros em disco
- Discos modernos fazem escalonamento interno

Escalonador de pedidos do SO

- Ordem de pedidos (escalonamento) é importante, a sua otimização varia com a workload
  - Deadline mantém filas distintas para escritas e leituras, dando maior prioridade às últimas. Bom quando leituras têm maior probabilidade de bloquear processos
  - Completely Fair Queueing scheduler (CFQ) mantém filas com diferentes prioridades (usado para discos SATA)
  - NOOP não implementa qualquer política. Bom para dispositivos NVM (PCIe).
- Outras considerações
  - prioridade à paginação sobre I/O de ficheiros
  - ordem de escrita de meta-dados do sistema de ficheiros
- SO pode escalonar conjuntos de pedidos; disco gere cada conjunto

Gestão de discos

- Formatação física: divisão (baixo-nível) do disco em sectores a que o controlador acede
- Particionamento: divisão lógica (nível SO) do disco em partes independentes. P.ex. para suportar diferentes sistemas de ficheiros
- Formatação lógica: criação de sistema de ficheiros, com estruturas de dados em disco
- Raw disks:
  - partições que não contêm sistemas de ficheiros
  - vistas como array de blocos lógicos
  - acedidas directamente por aplicações como bases de dados
- Bloco de boot:
  - é carregado pelo programa inicial de bootstrap em ROM
  - contém programa de bootstrap que carrega o SO para memória

Bad Sectors

- Bad sectors:
  - alguns vêm marcados de fábrica
  - formatação física deixa sectores extra de lado, invisíveis ao SO
  - quando se danificam outros, são substituídos por sectores extra
  - ECC error-correcting code usado para cada sector
  - substituição antecipada se ocorrerem soft errors, recuperáveis, antes que aconteçam hard errors
- Substituição de bad sectors – sector sparing ou forwarding
  - sector danificado é mapeado em sector extra
  - feita pelo controlador; transparente para o SO
  - pode invalidar optimizações do algoritmo de escalonamento
  - solução: são mantidos sectores extra em cada cilindro
- Substituição de bad sectors – sector slipping
  - em alternativa a sparing
  - move um conjunto de sectores na direcção de sector extra livre
  - re-mapeia o conjunto para a nova gama

Área de swap

- Área de swap é usada pelo sistema de memória virtual
- Dimensionamento por excesso pode ser conveniente:
  - discos baratos
  - evita terminar processos
- Duas alternativas de gestão:
  - ficheiro grande, guardado dentro de sistema de ficheiros
  - é mantida numa partição raw, à parte
- Partição própria de swap mais eficiente:
  - evita aceder a estruturas do sistema de ficheiros
  - não corre o perigo de o ficheiro estar disperso pelo disco
  - pode usar algoritmos especializados
  - desvantagem: dificuldade em aumentar área de swap
- Pode estar dividida por vários discos: aumenta largura de banda

Gestão da área de swap

Evolução:

- Inicialmente era feito swap de processos inteiros para região contígua (daí nome)
- Com hardware de paginação, swapping e paging coexistiram
- 4.3BSD: swap alocado quando processo arranca; para código e dados
- Solaris 1 (SunOS): páginas de código são trazidas do sistema de ficheiros e descartadas quando necessário; não vão para swap
- Solaris 2: swap alocado apenas quando página é rejeitada; não quando criada

Swap map em Linux

- Linux pode ter várias áreas de swap, em ficheiro ou partição raw
- Cada área é um vector de blocos de 4KB para guardar páginas
- A cada área é associada um swap map:
  - vector de inteiros, 1 por bloco
  - $=0$: bloco livre
  - >0: contador de número de processos que partilham página

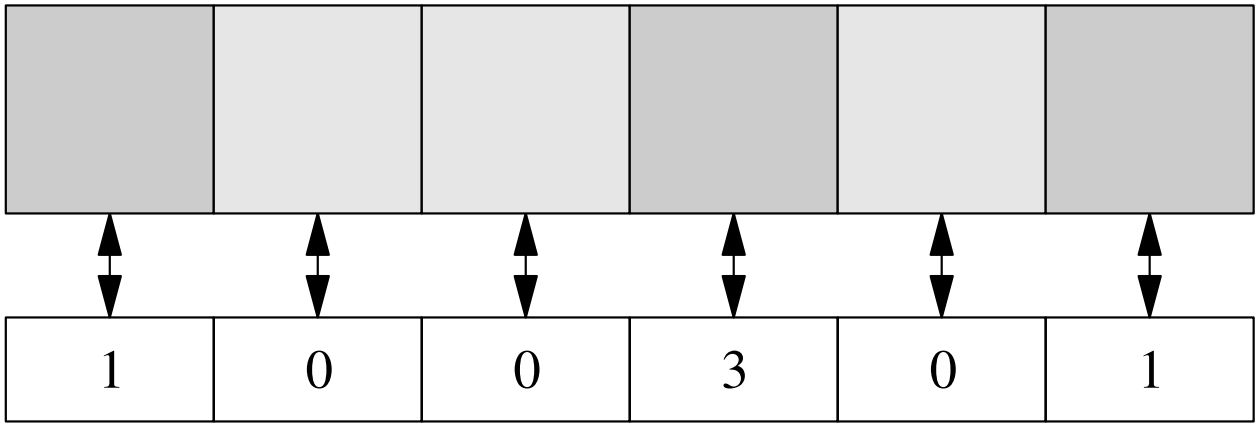

RAID

- RAID – redundant array of independent disks
- Ligação de vários discos trabalhando cooperativamente
- Podem melhorar performance trabalhando em paralelo
- Podem melhorar fiabilidade à custa de redundância
- Disco hot spare em stand-by permite reconstituir o RAID se houver falha de disco
- Implementação por software, ou hardware transparente ao SO
- Diferentes variantes de RAID

Melhoria de fiabilidade

- Introdução de redundância no armazenamento
- Mirroring: duplicação de cada disco
  - cada disco lógico é constituído por 2 discos físicos
  - cada escrita é feita nos 2 discos
  - se um disco falha, dados podem ser lidos do outro
- Quando um disco falha é reparado/substituído e dados copiados
- Probabilidade de perda de dados muito menor
- Minimizar correlação de falhas: e.g. usar discos de diferentes fabricantes ou com diferentes datas de fabrico

Melhoria de desempenho

- Com mirroring:
  - as escritas têm que ir para os 2 discos: mesmo desempenho
  - 2 leituras podem ser feitas em paralelo: dobro do desempenho
- Striping – dividir os dados ao longo de n discos
  - bit-level: 1 bit para cada disco: bit i para disco ($i \bmod n$)
  - outras possibilidades: byte-level, sector-level, block-level
  - mais comum: block-level – espalha blocos de ficheiro
- Striping permite, através de paralelismo:
  - melhorar throughput de acessos pequenos, via load-balancing
  - reduzir tempo de resposta de acessos grandes (melhor utilização da capacidade de transferência - largura de banda)

Níveis de RAID

- Várias combinações são possíveis em termos de mirroring, striping, ou uso de bits de paridade
- RAID Level 0: striping a nível do bloco
- RAID Level 1: uso de mirroring
- RAID Level 2: memory-style error-correcting code organization
  - uso de bit-level striping com bits ECC em discos extra
  - 3 discos extra por cada 4 discos de dados
  - melhora fiabilidade com menos discos do que RAID 1
- RAID Level 3: bit-interleaved parity organization
  - melhora RAID 2, usando apenas 1 disco extra com bit de paridade
  - aproveita o facto de discos já conterem ECCs e detectarem erros
  - sabendo qual o disco com erro 1 bit de paridade é suficiente
  - melhora fiabilidade; usado em vez de RAID 2

Níveis de RAID

- RAID Level 4: block-interleaved parity organization
  - como RAID 3 mas com block-level striping
  - leituras a blocos diferentes podem seguir em paralelo
  - melhora throughput para acessos pequenos
  - escritas pequenas exigem ler e escrever dados e paridade
- RAID Level 5: block-interleaved distributed parity
  - parecido com RAID 4; mas com paridade espalhada pelos discos
  - com d discos, paridade do bloco b no disco ($b \bmod d$)
  - evita sobrecarregar um único disco de paridade como em RAID 4
  - é o nível de RAID com paridade mais comum
- RAID Level 6: P + Q redundancy scheme
  - parecido com RAID 5 mas com ECC em vez de paridade
  - com 2 bits redundantes por 4 bits de dados tolera 2 falhas (i.e., tolera mais falhas de discos simultâneas que RAID 3, 4 ou 5)
  - necessita de mais discos (p.ex. 6 discos para 4 de dados, em vez de 5 discos para 4 de dados como os RAID 3, 4 ou 5)

Níveis de RAID

- RAID Level 0+1: combinação de RAID 0 com RAID 1
  - RAID 0 para desempenho e RAID 1 para fiabilidade
  - discos são striped e o conjunto mirrored
  - dispendioso como RAID 1 (dobro dos discos)
  - mais performance do que RAID 5
- RAID Level 1+0: variante de RAID 0+1
  - discos são mirrored aos pares
  - os pares são striped
  - vantagem sobre 0+1: se um disco falha, o par continua disponível (em 0+1 se disco falha, a stripe inteira fica inacessível)